

Fiche Synthèse : De MongoDB à Plotly

1. La Base : Connexion à MongoDB

```
from pymongo import MongoClient

# Connexion au serveur local
client = MongoClient("mongodb://localhost:27017/")

# Sélection de la base et de la collection
db = client["test"]
collection = db["movies"]
```

2. Exemple Simple : Lire tous les films et afficher un graphique

On récupère les documents bruts et on génère un graphique rapide avec `plotly.express`.

```
import pandas as pd
import plotly.express as px

# 1. Récupération des films depuis MongoDB
cursor = collection.aggregate([{"_id": "$year", "count": { "$count": {} } }])

# 2. Conversion en DataFrame Pandas
df = pd.DataFrame(list(cursor))

df_bucket.rename(columns={'_id': 'annee'}, inplace=True)

# 3. Affichage du graphique simple (Nombre de films par genre)
fig = px.bar(df, x="annee", title="Nombre de films par année")
fig.show()
```

3. Exemple Avancé : Décennies (\$bucket) et Boîte à moustaches (px.box)

Pourquoi la boîte à moustaches ? Au lieu d'une simple moyenne qui peut être trompeuse, le *Box Plot* montre la médiane, la dispersion des notes et les films extrêmes pour chaque décennie.

Étape A : Le pipeline d'agrégation MongoDB (\$bucket)

On utilise `$bucket` pour définir les tranches de 10 ans et `$push` pour regrouper la liste des notes de chaque décennie.

```
pipeline = [  
    {  
        # Regroupement par tranches de 10 ans sur le serveur MongoDB  
        "$bucket": {  
            "groupBy": "$year",  
            "boundaries": [1950, 1960, 1970, 1980, 1990, 2000, 2010, 2020],  
            "output": {  
                "tous_les_scores": {"$push": "$score"} # Récupère tous les scores  
de la décennie  
            }  
        }  
    }  
]  
  
cursor = collection.aggregate(pipeline)
```

Étape B : Transformation minimale et Box Plot avec Plotly

```
import pandas as pd  
import plotly.express as px  
  
# 1. Conversion du résultat MongoDB en DataFrame  
df_bucket = pd.DataFrame(list(cursor))  
df_bucket.rename(columns={'_id': 'decennie'}, inplace=True)  
  
# 2. Déplier la liste des scores pour alimenter le Box Plot  
df_flat = df_bucket.explode('tous_les_scores')  
  
# 3. Graphique en boîte à moustaches  
fig_box = px.box(  
    df_flat,  
    x="decennie",  
    y="tous_les_scores",  
    points="outliers", # Affiche les valeurs extrêmes sous forme de points  
    title="Distribution des notes de films par décennie",  
    labels={"decennie": "Décennie (Année de début)", "tous_les_scores": "Note (1-  
10)"}  
)  
  
fig_box.show()
```